TEORÍA DE LA DECISIÓN

Sesión #10: Estadística Bayesiana – II
Distribuciones A Priori, A Posteriori y Pruebas de Hipótesis

Prof. Brigitte Castañeda, Ph.D.

Departamento de Ingeniería Industrial
Universidad de los Andes

21 de octubre de 2026

Contenido de la sesión

- **Teorema de Bayes para parámetros discretos (i.i.d.)**
- **Teorema de Bayes para parámetros continuos:**
  - Contexto y fundamentación.
  - Enunciado e interpretación del teorema.
  - Familias conjugadas (Modelo Beta–Binomial).

Características distintivas de la inferencia bayesiana

1. **Incertidumbre Subjetiva Paramétrica:** La incertidumbre sobre un parámetro se modela directamente como una variable aleatoria dotada de una distribución de probabilidad.
2. **Condicionamiento Intuitivo:** Resulta metodológicamente más sencillo estructurar probabilidades condicionales a estados hipotéticos ($P(\text{Dato} \mid \text{Estado})$) que estimar conjuntas globales directas.
3. **Producto Final Completo:** La inferencia bayesiana entrega una **distribución de probabilidad completa a posteriori**, no un estimador puntual aislado.
4. **Intervalos de Credibilidad vs. Confianza:** Mientras la estadística clásica genera intervalos de confianza frecuentistas, el enfoque bayesiano permite calcular directamente:

$$P(a \leq \theta \leq b \mid M)$$

Teorema de Bayes para parámetros discretos con muestra i.i.d.

Teorema Formal de Bayes para Muestras Aleatorias

Sea X una variable aleatoria con función de probabilidad $f_X(x;\theta)$, dependiente de un parámetro discreto $\theta \in \Theta = \{\theta_1, \theta_2, \ldots, \theta_m\}$ con distribución *a priori* $g(\theta)$.

Dada una muestra aleatoria independiente e idénticamente distribuida (i.i.d.) $M = (x_1, x_2, \ldots, x_n)$, la **distribución a posteriori** viene dada por:

$$h(\theta_k \mid x_1, x_2, \ldots, x_n) = \frac{\left[\prod_{i=1}^{n} f_X(x_i;\theta_k)\right] g(\theta_k)}{\sum_{j=1}^{m} \left[\prod_{i=1}^{n} f_X(x_i;\theta_j)\right] g(\theta_j)}$$

Referencia bibliográfica: Demostración formal en pág. 247 del texto guía del curso.

Demostración: TB para parámetros discretos

1. Definición de Probabilidad Condicional

Queremos hallar la distribución *a posteriori* $h(\theta \mid x_1, \ldots, x_n)$:

$$h(\theta \mid x_1, \ldots, x_n) = \frac{f(x_1, \ldots, x_n, \theta)}{f(x_1, \ldots, x_n)}$$

2. Numerador (Regla del Producto e Independencia)

Por regla de probabilidad condicional e independencia muestral condicionada a θ:

$$f(x_1, \ldots, x_n, \theta) = \left[\prod_{i=1}^{n} f(x_i \mid \theta)\right] \cdot g(\theta)$$

$$\text{Numerador} = \mathcal{L}(x_1, \ldots, x_n \mid \theta) \cdot g(\theta)$$

3. Denominador (Ley de Probabilidad Total)

Marginalizamos sobre el espacio discreto $\Theta = \{\theta_1, \ldots, \theta_k\}$:

$$f(x_1, \ldots, x_n) = \sum_{j=1}^{k} \left[\prod_{i=1}^{n} f(x_i \mid \theta_j)\right] g(\theta_j)$$

4. Ensamble de la Fórmula

$$h(\theta_k \mid x_1, \ldots, x_n) = \frac{\left[\prod_{i=1}^{n} f(x_i \mid \theta_k)\right] g(\theta_k)}{\sum_{j=1}^{k} \left[\prod_{i=1}^{n} f(x_i \mid \theta_j)\right] g(\theta_j)}$$

La Regla Proporcional Fundamental

Dado que el denominador es una constante k dependiente sólo de los datos observados:

$$h(\theta \mid \textbf{datos}) = k \cdot \mathcal{L}(\textbf{datos} \mid \theta) \cdot g(\theta)$$

A Posteriori $\propto$ Verosimilitud $\times$ A Priori

Ejemplo: en exploración petrolera

1. Parámetros y Datos de Entrada

- **Estados (θ) El estado real del pozo petrolero:** $\theta_1 =$ No Exitoso, $\theta_2 =$ Exitoso.
- **A Priori $g(\theta)$:**
  - $P(\theta_1) = 0{,}40$, (40 % de los pozos de la región son no exitosos)
  - $P(\theta_2) = 0{,}60$ (60 % de los pozos de la región son exitosos).
- **Evidencia (x_1):** Sísmica predice que el pozo **NO será exitoso** (evento x_1).
- **Verosimilitud $\mathcal{L}(x_1 \mid \theta)$:**
  - Si el pozo es realmente No Exitoso (θ_1): la sísmica lo predice como no exitoso $P(x_1 \mid \theta_1) = 0{,}90$.
  - Si el pozo es realmente Exitoso (θ_2): la sísmica falla y lo predice como no exitoso $P(x_1 \mid \theta_2) = 0{,}30$.

Queremos calcular la probabilidad a posteriori de que el pozo no sea exitoso, sabiendo que la sísmica arrojó alerta de fallo ($h(\theta \mid x_1)$)

Ejemplo: en exploración petrolera

1. Probabilidad Condicional:

$$h(\theta_i \mid x_1) = \frac{f(x_1, \theta_i)}{f(x_1)} = \frac{f(x_1 \mid \theta_i) \cdot g(\theta_i)}{f(x_1)}$$

2. Numeradores (Verosimilitud $\times$ A Priori):

$$f(x_1, \theta_1) = f(x_1 \mid \theta_1) \cdot g(\theta_1) = (0{,}90) \times (0{,}40) = \mathbf{0{,}36}$$
$$f(x_1, \theta_2) = f(x_1 \mid \theta_2) \cdot g(\theta_2) = (0{,}30) \times (0{,}60) = \mathbf{0{,}18}$$

3. Denominador (Ley de Probabilidad Total):

$$f(x_1) = \sum_{\theta_i} f(x_1 \mid \theta_i) \cdot g(\theta_i) = 0{,}36 + 0{,}18 = \mathbf{0{,}54}$$

4. Calcular la Distribución A Posteriori Normalizada $h(\theta \mid x_1)$:

$$h(\theta_1 \mid x_1) = \frac{0{,}36}{0{,}54} = \frac{\mathbf{2}}{\mathbf{3}} \approx \mathbf{0{,}67} \quad (67\,\%)\text{No Existoso}$$

$$h(\theta_2 \mid x_1) = \frac{0{,}18}{0{,}54} = \frac{\mathbf{1}}{\mathbf{3}} \approx \mathbf{0{,}33} \quad (33\,\%)\text{Existoso}$$

Ejemplo: en exploración petrolera

Actualización del Conocimiento

Estado (θ)	**A Priori $g(\theta)$**	**A Posteriori $h(\theta \mid x_1)$**
θ_1 (No Exitoso)	40 %	**66.7 %** $\uparrow$
θ_2 (Exitoso)	60 %	**33.3 %** $\downarrow$

Teorema de Bayes para parámetros continuos

Contexto: Se tiene una variable aleatoria X con fdp o fp $f_X(x \mid \theta)$, la cual depende de un parámetro θ continuo, que es a su vez una variable aleatoria con fdp *a priori* $g(\theta)$ y rango $R(\theta) = \Theta$.
Se quiere obtener la distribución *a posteriori* del parámetro θ, dada una muestra aleatoria $x_1, x_2, \ldots, x_n$ de X.

Enunciado: la distribución a posteriori del parámetro θ está dada por

$$h(\theta \mid x_1, \ldots, x_n) = \frac{\left[\prod_{i=1}^{n} f_X(x_i \mid \theta)\right] g(\theta)}{\displaystyle\int_{R(\theta)} \left[\prod_{i=1}^{n} f_X(x_i \mid \theta)\right] g(\theta)\, d\theta}$$

Para una muestra aleatoria genérica M, la expresión toma la forma compacta:

$$h(\theta \mid M) = \frac{P(M \mid \theta) g(\theta)}{\displaystyle\int_{R(\theta)} P(M \mid \theta) g(\theta)\, d\theta}$$

Teorema de Bayes para parámetros continuos: conjugación

En general, se tiene la siguiente relación de proporcionalidad:

$$\mathbf{h}(\theta \mid \mathbf{x}) \propto \mathbf{P}(\mathbf{M} \mid \theta) \cdot \mathbf{g}(\theta)$$

Familias Conjugadas

Cuando $h(\theta \mid x) \sim g(\theta)$; es decir, pertenece a la misma familia de distribuciones, decimos que $g(\theta)$ **es conjugada para la función de verosimilitud** $P(M \mid \theta)$. Esto simplifica enormemente los cálculos algebraicos.

Ejemplo: Tenemos un experimento de tirar moneda cara-cruz, la lanzamos N veces.
Sea x: número de caras.
Suponer que la distribución a priori, sigue una distribución continua, **Beta**.

- **A Priori Beta:** $g(\theta) \sim \theta^{a-1}(1-\theta)^{b-1}$
- **Verosimilitud Binomial (LF):** $P(x \mid \theta) \sim \theta^{x}(1-\theta)^{N-x}$

Agrupando las expresiones anteriores, la función *a posteriori* queda en la misma familia **Beta**.

Modelo Beta–Binomial conjugado

Multiplicando el núcleo de la verosimilitud por la previa:

$$h(\theta \mid x) \propto \left[\theta^{x}(1-\theta)^{N-x}\right] \cdot \left[\theta^{a-1}(1-\theta)^{b-1}\right]$$

Agrupando términos con la misma base:

$$\mathbf{h}(\theta \mid \mathbf{x}) \propto \theta^{(\mathbf{a}+\mathbf{x})-\mathbf{1}}(\mathbf{1}-\theta)^{(\mathbf{b}+\mathbf{N}-\mathbf{x})-\mathbf{1}}$$

La distribución *a posteriori* es proporcional a una distribución **Beta** con parámetros actualizados:

$$\theta \mid \mathbf{x} \sim \text{Beta}(\mathbf{a}+\mathbf{x},\ \mathbf{b}+\mathbf{N}-\mathbf{x})$$

Verosimilitud: Binomial + **A Priori: Beta** $\Longrightarrow$ **A Posteriori: Beta**

Resumen de distribuciones: funciones de probabilidad y densidad

Distribución	Tipo	Rango / Dominio	¿Qué pregunta responde?	Función de Probabilidad (`fp`) / Densidad (`fdp`)
Bernoulli	Discreta (`fp`)	$x \in \{0, 1\}$	¿Hubo éxito o fracaso en **1 intento**?	$f(x \mid p) = p^x(1-p)^{1-x}$
Binomial	Discreta (`fp`)	$x \in \{0, 1, \ldots, n\}$	¿Cuántos éxitos hubo en n **intentos fijos**?	$f(x \mid n, p) = \binom{n}{x} p^x(1-p)^{n-x}$
Poisson	Discreta (`fp`)	$x \in \{0, 1, 2, \ldots, \infty\}$	¿Cuántos eventos ocurrieron en **un periodo de tiempo**?	$f(x \mid \lambda) = \dfrac{e^{-\lambda}\lambda^x}{x!}$
Exponencial	Continua (`fdp`)	$x \in [0, \infty)$	¿Cuánto **tiempo** pasó hasta el **1.er evento**?	$f(x \mid \lambda) = \lambda e^{-\lambda x}$
Gamma	Continua (`fdp`)	$x \in (0, \infty)$	¿Cuánto tiempo pasó hasta el r-**ésimo evento**? / ¿Cuál es la tasa λ?	$f(x \mid r, \lambda) = \dfrac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x}$
Beta	Continua (`fdp`)	$\theta \in [0, 1]$	¿Cuál es la proporción, porcentaje o **probabilidad** θ?	$g(\theta \mid a, b) = \dfrac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1}(1-\theta)^{b-1}$
Normal	Continua (`fdp`)	$x \in (-\infty, \infty)$	¿Cuál es el valor de una magnitud simétrica en todo $\mathbb{R}$?	$f(x \mid \mu, \sigma^2) = \dfrac{1}{\sigma\sqrt{2\pi}} \exp\left(-\dfrac{(x-\mu)^2}{2\sigma^2}\right)$

Resumen de distribuciones y parejas conjugadas

Distribución	Tipo	Rango	¿Qué pregunta responde?	Pareja Bayesiana Clásica (Verosimilitud $\leftrightarrow$ Prior)
Bernoulli	Discreta (`fp`)	$\{0, 1\}$	¿Hubo éxito o fracaso en **1 intento**?	Se modela su parámetro p con una **Beta**.
Binomial	Discreta (`fp`)	$\{0, 1, \ldots, n\}$	¿Cuántos éxitos hubo en n **intentos fijos**?	**Verosimilitud** cuyo parámetro $p \in [0, 1]$ se modela con una **Beta**.
Poisson	Discreta (`fp`)	$\{0, 1, 2, \ldots, \infty\}$	¿Cuántos eventos ocurrieron en **un periodo de tiempo**?	**Verosimilitud** cuya tasa $\lambda > 0$ se modela con una **Gamma**.
Exponencial	Continua (`fdp`)	$[0, \infty)$	¿Cuánto **tiempo** pasó hasta el **1.er evento**?	**Verosimilitud** cuya tasa $\lambda > 0$ se modela con una **Gamma**.
Gamma	Continua (`fdp`)	$(0, \infty)$	¿Cuánto tiempo pasó hasta el r-**ésimo evento**? / ¿Cuál es la tasa λ?	**Prior / Posterior conjugada** para tasas λ (Poisson / Exponencial).
Beta	Continua (`fdp`)	$[0, 1]$	¿Cuál es la proporción, porcentaje o **probabilidad** θ?	**Prior / Posterior conjugada** para proporciones θ (Binomial / Bernoulli).
Normal	Continua (`fdp`)	$(-\infty, \infty)$	¿Cuál es el valor de una magnitud simétrica en todo $\mathbb{R}$?	**Normal-Normal:** La media μ de una Normal se modela con otra **Normal**.

Regla de Oro para Modelación: Identifique primero el dominio físico del parámetro desconocido θ ($[0, 1]$, $(0, \infty)$ o $\mathbb{R}$) para seleccionar su familia conjugada natural.

Ejemplo 1: Inferencia bayesiana y distribución Beta

Parámetro θ: *efectividad* de un medicamento que se encuentra en fase de estudio, interpretada como la probabilidad de que, para un paciente seleccionado al azar, el medicamento sea efectivo. Por tanto, el parámetro θ debe cumplir que $0 < \theta < 1$.

Se tomó una MA de 3 pacientes, resultando que el medicamento fue efectivo en 2 de los pacientes.

Hallar la distribución *a posteriori* del parámetro θ dada la muestra M, suponiendo que la distribución *a priori* de θ, $g(\theta)$, es una distribución Uniforme en el intervalo $[0, 1]$. Es decir, tenemos que hallar $h(\theta; M(2; 3))$.

Para resolver este problema necesitamos utilizar la **función Beta**(a, b) y la **distribución Beta**:

- **Función Beta:** se define como la integral:

$$\text{Beta}(a, b) = \int_0^1 x^{a-1}(1-x)^{b-1}\, dx\,; \quad a, b \in \mathbb{R};\ a, b > 0$$

- **Distribución Beta:** una V.A. $X_{\beta(a,b)}$ tiene distribución **Beta** de parámetros $a, b > 0$, si su **fdp (Función de densidad de probabilidad)** está dada por:

$$f_{X_{\beta(a,b)}}(x) = \frac{x^{a-1}(1-x)^{b-1}}{\text{Beta}(a, b)}\,, \quad \text{para } 0 \leq x \leq 1;\ a, b \in \mathbb{R},\ a, b > 0$$

Ejemplo 1: Cálculo de la distribución *a posteriori*

Distribución a posteriori: aplicando el Teorema de Bayes para parámetros continuos obtenemos que:

$$h(\theta; M(2;3)) = \frac{P(M(2;3) \mid \theta)\, g(\theta)}{\displaystyle\int_{R(\theta)} P(M(2;3) \mid \theta)\, g(\theta)\, d\theta}$$

Observación: el hecho de que $g(\theta)$ tenga una distribución Uniforme en $[0,1]$, siendo esta una distribución *vaga* (no informativa), denota máxima incertidumbre inicial, pues no se sabría a priori si el medicamento es bueno o malo ($g(\theta) = 1$).

Desarrollo Analítico y Reconocimiento de la Familia Beta

$$h(\theta; M(2;3)) = \frac{\binom{3}{2}\theta^2(1-\theta)^1 \cdot 1}{\displaystyle\int_0^1 \binom{3}{2}\theta^2(1-\theta)^1 \cdot 1\, d\theta} = \frac{\theta^{3-1}(1-\theta)^{2-1}}{\displaystyle\int_0^1 \theta^{3-1}(1-\theta)^{2-1}\, d\theta} = \mathbf{f}_{\mathbf{X}_{\beta(3,2)}}(\theta)$$

Esto quiere decir que, al contar con nueva evidencia experimental, **estamos ganando información**: la distribución pasa de ser plana (difusa) a concentrarse alrededor de los resultados observados.

Simulación Computacional

- Veamos este comportamiento gráficamente en **RStudio**.

¿Qué ocurre si la previa no es conjugada?
Veamos el siguiente ejemplo...

Ejemplo 2: Participación de mercado con priori triangular

Parámetro θ: representa la participación de mercado expresado en decimales de una nueva marca de un nuevo producto que no conocemos su aceptación. Por tanto, el parámetro θ, debe cumplir que, $0 < \theta < 1$. Si atrae gran participación, θ es cercana a uno, si no es exitosa, θ es de cero. Se asume que θ es continua y también que valores pequeños de θ son más probables que valores grandes. Por ello, consideramos la distribución *a priori* como una variante de la distribución triangular:

$$g(\theta) = \begin{cases} 2(1-\theta), & 0 \leq \theta \leq 1 \\ 0, & \text{d.l.c.} \end{cases}$$

Para tener más información de θ, Se encuestaron 5 consumidores. 3 compran la marca anterior y $x = 2$ compran la nueva marca. Se puede representar por una distribución Beta, donde

Función de Verosimilitud:

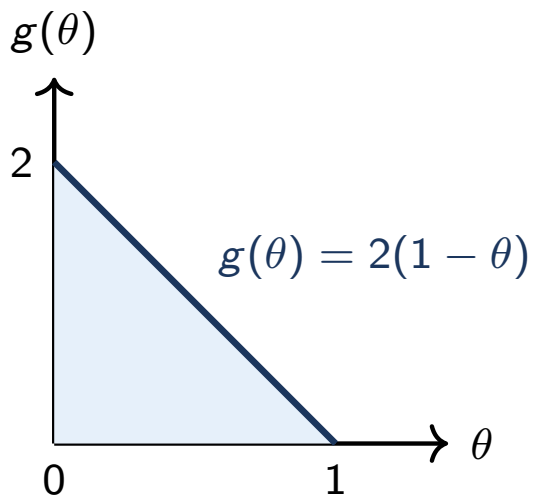
$$P(M \mid \theta) = \binom{5}{2}\theta^{5-1}(1-\theta)^{2-1} = 10\theta^4(1-\theta)^1$$

Objetivo: Determinar la distribución *a posteriori* aplicando:

$$h(\theta \mid M) = \frac{P(M \mid \theta)g(\theta)}{\int P(M \mid \theta)g(\theta)d\theta}$$

Ejemplo 2: Solución analítica y curva a posteriori

¿Qué es una distribución triangular? Es una distribución continua definida por un mínimo, un máximo y una moda (el pico del triángulo). En nuestro ejemplo de la nueva marca, sabemos que la participación θ está entre 0 y 1, y que al ser un producto nuevo es mucho más probable tener participaciones bajas cercanas a cero que capturar todo el mercado.



Ejemplo 2 (cont, solución)

. . . Aplicando ecuación:

$$h(\theta \mid M) = \frac{P(M \mid \theta) g(\theta)}{\int P(M \mid \theta) g(\theta) d\theta}$$

Tenemos:

$$h(\theta \mid M) = \frac{P(M \mid \theta) g(\theta)}{\int P(M \mid \theta) g(\theta) d\theta} = \frac{\left[10\theta^4(1-\theta)\right]\left[2(1-\theta)\right]}{\int_0^1 \left[10\theta^4(1-\theta)\right]\left[2(1-\theta)\right] d\theta}$$

$$= \frac{20\,\theta^4(1-\theta)^2}{20\int_0^1 \theta^4(1-\theta)^2 d\theta} = \frac{\theta^4(1-\theta)^2}{1/105} = 105\,\theta^4(1-\theta)^2$$

Por tanto, la distribución *a posteriori* es:

$$\mathbf{h}(\theta \mid \mathbf{M}) = \begin{cases} 105\,\theta^4(1-\theta)^2 & si\ 0 \le \theta \le 1 \\ 0 & d.l.c \end{cases}$$

