TEORÍA DE LA DECISIÓN

Sesión #12: Redes Bayesianas
Conceptos básicos y aplicaciones

Prof. Brigitte Castañeda, Ph.D.

Departamento de Ingeniería Industrial
Universidad de los Andes

28 de octubre de 2026

Contenido de la sesión

- **¿Qué es una Red Bayesiana?**
  - Nodos, arcos y tablas de probabilidad condicional.
  - Vocabulario del grafo: padres, hijos, ancestros, descendientes.
- **Propiedad de Markov y factorización:**
  - Independencia condicional: *"dados sus padres, un nodo ignora a sus no-descendientes"*.
  - Probabilidad conjunta como producto de condicionales.
  - Ejemplos de verificación de la condición de Markov.
- **Cálculo de una red:**
  - Modelo básico ($Y, Z \to X$) y ejemplo GNP – Educación – Salario.
- **Aplicaciones:** problemas reales y caso *Spam*.

¿Qué es una Red Bayesiana?

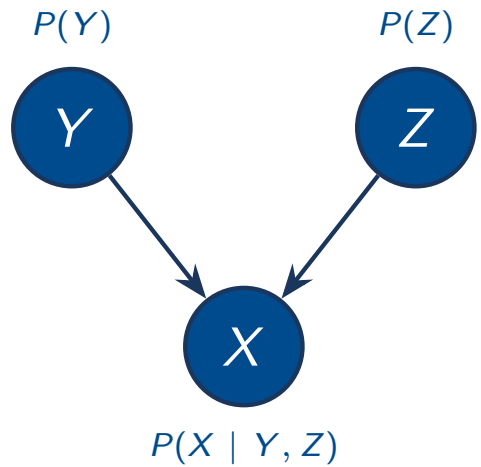
Las Redes Bayesianas también se conocen como **Redes Probabilísticas Causales**.

Definición

Una Red Bayesiana es un grafo que representa las relaciones de causalidad probabilística entre variables aleatorias, y permite resolver problemas de decisión bajo riesgo e incertidumbre.

Está compuesta por:

- **Nodos** $\rightarrow$ variables aleatorias, con una distribución de probabilidad asignada (nodos raíz) o calculada (nodos con padres).
- **Arcos** $\rightarrow$ relaciones entre nodos, cuantificadas con **probabilidades condicionales**.
- **Tablas de probabilidad condicional (TPC)** $\rightarrow$ $P(\text{nodo} \mid \text{padres})$.

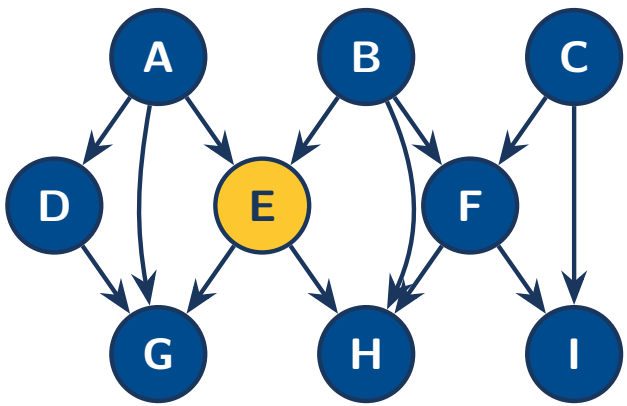


Conceptos de Neapolitan (2004) y Torres (2002). Lectura: Castillo, Cap. 7.

El grafo: un GDA $G = (V, E)$

La red se representa por un **Grafo Dirigido Acíclico** (GDA):

- V: conjunto no vacío de **nodos** (vértices) = variables aleatorias.
- E: conjunto de **arcos**; cada arco es una **pareja ordenada** (X, Y) = flecha $X \to Y$ (el orden da la dirección). Si hay un arco de X a Y (o de Y a X), X y Y son **adyacentes**.
- **Acíclico:** siguiendo las flechas nunca se regresa al nodo de partida.



Vocabulario (respecto al nodo E)

- **Padres** $PA(E)$: $\{A, B\}$
- **Hijos**: $\{G, H\}$
- **Ancestros**: $\{A, B\}$ (hay un camino dirigido hacia E)
- **Descendientes**: $\{G, H\}$ (se alcanzan desde E siguiendo flechas)
- **No-descendientes** $ND(E)$: $\{A, B, C, D, F, I\}$

Condición de Markov (independencia condicional)

Condición de Markov

Cada variable es **condicionalmente independiente de sus no-descendientes, dados sus padres**:

$$X_i \perp\!\!\!\perp ND(X_i) \mid PA(X_i)$$

$$\iff \quad P\big(X_i \mid PA(X_i), ND(X_i)\big) = P\big(X_i \mid PA(X_i)\big)$$

Intuición: una vez conocemos los padres de un nodo, cualquier otro nodo que no sea su descendiente ya no aporta información sobre él.

Condición de Markov (independencia condicional)

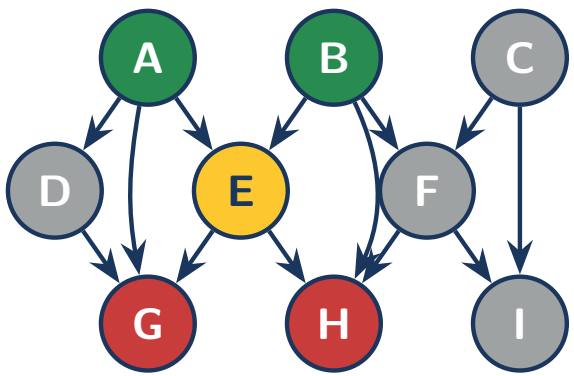
Condición de Markov

Cada variable es **condicionalmente independiente de sus no-descendientes, dados sus padres**:

$$X_i \perp\!\!\!\perp ND(X_i) \mid PA(X_i)$$

$$\iff \quad P\big(X_i \mid PA(X_i), ND(X_i)\big) = P\big(X_i \mid PA(X_i)\big)$$

Intuición: una vez conocemos los padres de un nodo, cualquier otro nodo que no sea su descendiente ya no aporta información sobre él.



padres descendientes no-descendientes (no padres)

Para el nodo E:

$$E \perp\!\!\!\perp \{C, D, F, I\} \mid \{A, B\}$$

$$P(E \mid A, B, C, D, F, I) = P(E \mid A, B)$$

Ojo: G y H (descendientes) **sí** pueden cambiar lo que sabemos de E.

Factorización recursiva: el resultado central

Teorema 1 (de la red a la conjunta)

Sea G una red bayesiana acíclica y P la distribución conjunta de sus variables. Entonces P **es igual al producto de las distribuciones condicionales de todos los nodos dados sus padres**; decimos que P **se factoriza sobre** G.

Teorema 2 (de las condicionales a la conjunta)

Si a cada nodo de un GDA G se le asocia una probabilidad condicional dados sus padres, el **producto** de estas condicionales genera una probabilidad conjunta que **satisface la Propiedad de Markov**.

Factorización recursiva:

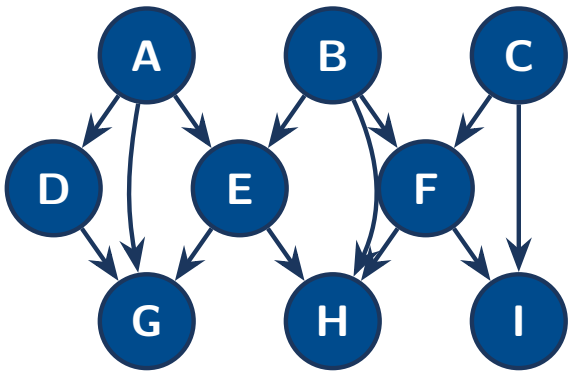
$$\mathbf{P(X_1, X_2, \ldots, X_n) = \prod_{i=1}^{n} P\left(X_i \mid PA(X_i)\right)}$$

¿Por qué importa? Con la regla de la cadena general, cada factor depende de *todas* las variables anteriores. Gracias a la independencia condicional, cada factor depende **solo de los padres** $\Rightarrow$ muchos menos parámetros por especificar.

Ref.: *Machine Learning*, Elsevier (2015). doi:10.1016/B978-0-12-801522-3.00016-1

Aplicando la factorización a una red

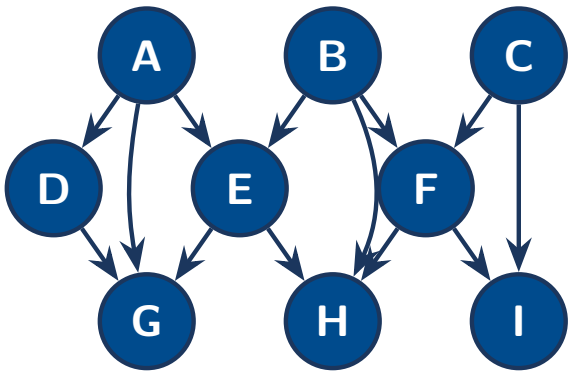
Usando la propiedad de Markov, la conjunta de la red se escribe nodo por nodo, **"cada nodo dado sus padres"**:



Nodo	Padres	Factor
A, B, C	– (raíces)	$P(A)\,P(B)\,P(C)$
D	A	$P(D \mid A)$
E	A, B	$P(E \mid A, B)$
F	B, C	$P(F \mid B, C)$

Aplicando la factorización a una red

Usando la propiedad de Markov, la conjunta de la red se escribe nodo por nodo, **"cada nodo dado sus padres"**:

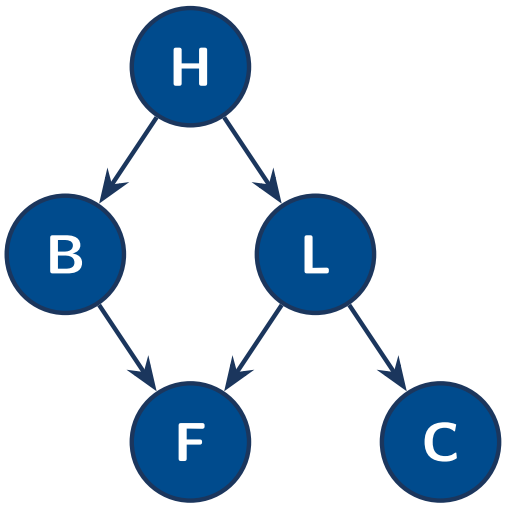


Nodo	Padres	Factor
A, B, C	– (raíces)	$P(A)\,P(B)\,P(C)$
D	A	$P(D \mid A)$
E	A, B	$P(E \mid A, B)$
F	B, C	$P(F \mid B, C)$
G	A, D, E	$P(G \mid A, D, E)$
H	B, E, F	$P(H \mid B, E, F)$
I	C, F	$P(I \mid C, F)$

$$P(A, B, C, D, E, F, G, H, I) = P(A)\,P(B)\,P(C)\,P(D \mid A)\,P(E \mid A, B)$$
$$\cdot\, P(F \mid B, C)\,P(G \mid A, D, E)\,P(H \mid B, E, F)\,P(I \mid C, F)$$

Ejemplo 1: verificando la condición de Markov

$$Y_i \perp\!\!\!\perp ND(Y_i) \mid PA(Y_i)$$



Ejemplo de GDA

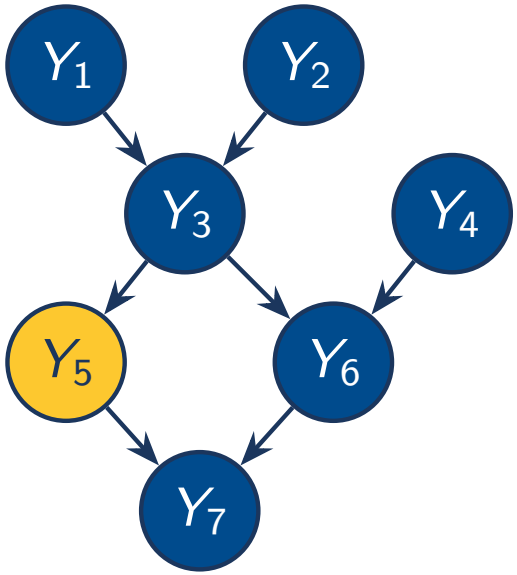
Nodo	Padres	Independencia condicional
C	L	$C \perp\!\!\!\perp \{H, B, F\} \mid L$
B	H	$B \perp\!\!\!\perp \{L, C\} \mid H$
F	B, L	$F \perp\!\!\!\perp \{H, C\} \mid \{B, L\}$
L	H	$L \perp\!\!\!\perp B \mid H$
H	–	(nodo raíz: no hay restricción)

Si (G, P) satisface la condición de Markov, P es el producto de las condicionales de todos los nodos dados sus padres:

$$\mathbf{P(f, c, b, l, h) = P(c \mid l)\, P(b \mid h)\, P(f \mid b, l)\, P(l \mid h)\, P(h)}$$

Ref.: R. Neapolitan, *Learning Bayesian Networks*, Prentice Hall, 2004.

Ejemplo 2: condición de Markov en una red más grande



Nodo	PA	Independencia condicional
Y_3	Y_1, Y_2	$Y_3 \perp\!\!\!\perp Y_4 \mid \{Y_1, Y_2\}$
Y_5	Y_3	$Y_5 \perp\!\!\!\perp \{Y_1, Y_2, Y_4, Y_6\} \mid Y_3$
Y_6	Y_3, Y_4	$Y_6 \perp\!\!\!\perp \{Y_1, Y_2, Y_5\} \mid \{Y_3, Y_4\}$
Y_7	Y_5, Y_6	$Y_7 \perp\!\!\!\perp \{Y_1, Y_2, Y_3, Y_4\} \mid \{Y_5, Y_6\}$

Factorización de la red

$$P(Y_1, \ldots, Y_7) = P(Y_1)\, P(Y_2)\, P(Y_3 \mid Y_1, Y_2)\, P(Y_4)\, P(Y_5 \mid Y_3)\, P(Y_6 \mid Y_3, Y_4)\, P(Y_7 \mid Y_5, Y_6)$$

Pregunta: ¿por qué basta conocer Y_3 para calcular la probabilidad de Y_5?

Ref.: Sebastiani, *Bayesian Networks for Genomic Analysis*, 2002; Neapolitan (2004).

Ejemplo 2: ¿por qué basta conocer Y_3?

Condicionamos Y_5 en **todos** sus no-descendientes y usamos la factorización (al sumar sobre Y_7 su factor vale 1):

$$P(Y_5 \mid Y_1, Y_2, Y_3, Y_4, Y_6) = \frac{P(Y_1, Y_2, Y_3, Y_4, Y_5, Y_6)}{P(Y_1, Y_2, Y_3, Y_4, Y_6)}$$

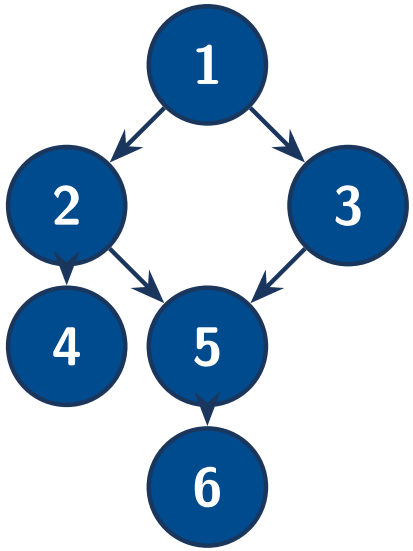
$$= \frac{P(Y_5 \mid Y_3)\, P(Y_3 \mid Y_1, Y_2)\, P(Y_6 \mid Y_3, Y_4)\, P(Y_1)\, P(Y_2)\, P(Y_4)}{P(Y_3 \mid Y_1, Y_2)\, P(Y_6 \mid Y_3, Y_4)\, P(Y_1)\, P(Y_2)\, P(Y_4)} = \mathbf{P(Y_5 \mid Y_3)}$$

Con solo los ancestros $\{Y_1, Y_2\}$ ocurre lo mismo:

$$P(Y_5 \mid Y_1, Y_2, Y_3) = \frac{P(Y_5 \mid Y_3)\, P(Y_3 \mid Y_1, Y_2)\, P(Y_1)\, P(Y_2)}{P(Y_3 \mid Y_1, Y_2)\, P(Y_1)\, P(Y_2)} = \mathbf{P(Y_5 \mid Y_3)}$$

Cada nodo es **condicionalmente independiente de todos sus no-descendientes**, dado el estado de sus padres. Una vez conocidos los padres, la influencia de cualquier nodo que no sea descendiente **puede ignorarse** al calcular su probabilidad. Ej.: $P(Y_5 \mid Y_3)$.

Ejemplo 3: independencias "inmediatas" y "menos inmediatas"



Inmediatas (directo de la condición de Markov)

$x_2 \perp\!\!\!\perp x_3 \mid x_1$

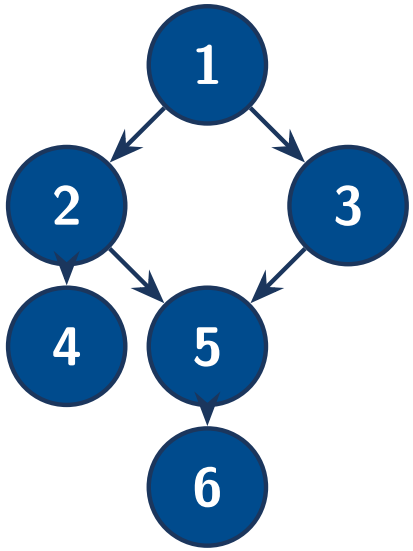
$x_3 \perp\!\!\!\perp x_2, x_4 \mid x_1$

$x_4 \perp\!\!\!\perp x_1, x_3, x_5, x_6 \mid x_2$

$x_5 \perp\!\!\!\perp x_1, x_4 \mid x_2, x_3$

$x_6 \perp\!\!\!\perp x_1, x_2, x_3, x_4 \mid x_5$

Ejemplo 3: independencias "inmediatas" y "menos inmediatas"



Inmediatas (directo de la condición de Markov)

$x_2 \perp\!\!\!\perp x_3 \mid x_1$

$x_3 \perp\!\!\!\perp x_2, x_4 \mid x_1$

$x_4 \perp\!\!\!\perp x_1, x_3, x_5, x_6 \mid x_2$

$x_5 \perp\!\!\!\perp x_1, x_4 \mid x_2, x_3$

$x_6 \perp\!\!\!\perp x_1, x_2, x_3, x_4 \mid x_5$

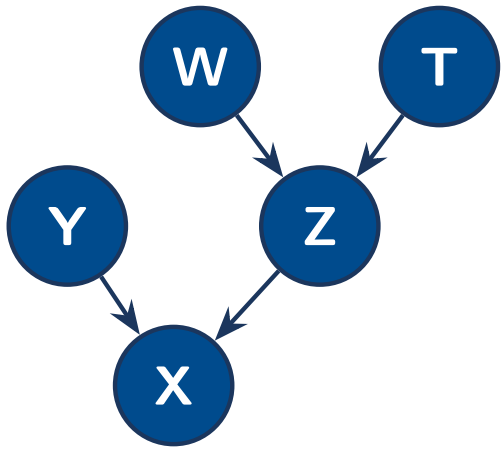
Menos inmediatas (se deducen de las anteriores)

$x_3 \perp\!\!\!\perp x_4 \mid x_1$

¿De dónde sale $x_3 \perp\!\!\!\perp x_4 \mid x_1$**?** De $x_3 \perp\!\!\!\perp \{x_2, x_4\} \mid x_1$ por **descomposición**: si x_3 es independiente de un conjunto, también lo es de cada parte. Gráficamente, todo camino entre 3 y 4 queda bloqueado: $3 \leftarrow \mathbf{1} \rightarrow 2 \rightarrow 4$ se corta al conocer x_1, y $3 \rightarrow 5 \leftarrow 2 \rightarrow 4$ se corta en 5 (dos flechas que llegan y x_5 no observado).

Ref.: *Markov property*, University of Illinois Urbana-Champaign, curso IE598.

Solución de una red usando la independencia condicional



Estados: $W: \{w_1, w_2\}$, $T: \{t_1, t_2\}$,
$Y: \{y_1, y_2, y_3\}$, $Z: \{z_1, z_2\}$,
$X: \{x_1, x_2\}$

Paso a paso (regla del producto + Markov):

$$\begin{aligned} P(X,Y,Z,W,T) &= P(X \mid Y,Z,W,T)\, P(Y,Z,W,T) \\ &= \underbrace{P(X \mid Y,Z)}_{\text{padres de } X}\, P(Z \mid Y,W,T)\, P(Y,W,T) \\ &= P(X \mid Y,Z)\, \underbrace{P(Z \mid W,T)}_{\text{padres de } Z}\, \underbrace{P(Y)\, P(W)\, P(T)}_{\text{raíces independientes}} \end{aligned}$$

Conclusión

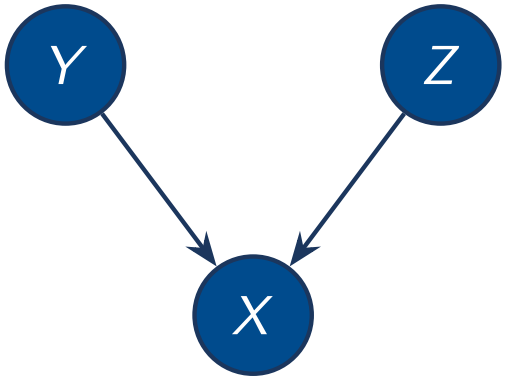
La probabilidad conjunta de las variables de la red es la **multiplicatoria de las probabilidades condicionales de cada nodo dados sus padres**.

En particular, para una combinación de estados:

$$P(x_1, y_3, z_2, w_2, t_1) = P(x_1 \mid y_3, z_2)\, P(z_2 \mid w_2, t_1)\, P(y_3)\, P(w_2)\, P(t_1)$$

Modelo básico: datos de entrada (*inputs*)

Red con dos causas Y, Z (independientes) y un efecto X. Todas las variables tienen dos estados.



Y	$P(Y)$
y_1	0,5
y_2	0,5

Z	$P(Z)$
z_1	0,7
z_2	0,3

TPC de X: $P(X \mid Y, Z)$

Y	y_1		y_2	
Z	z_1	z_2	z_1	z_2
x_1	0,8	0,3	0,6	0,5
x_2	0,2	0,7	0,4	0,5

Cada columna suma 1: es una distribución de X para cada combinación de padres.

Pregunta

¿Cuál es la probabilidad (marginal) de que X esté en el estado x_1?

Modelo básico: cálculo de $P(x_1)$ (*outputs*)

1. Descomponer el evento x_1 según todas las combinaciones de los padres (eventos disjuntos):

$$x_1 = x_1(y_1, z_1) \cup x_1(y_1, z_2) \cup x_1(y_2, z_1) \cup x_1(y_2, z_2)$$

$$P(x_1) = \sum_y \sum_z P(x_1 \mid y, z)\, P(y)\, P(z) \qquad (*)$$

2. Calcular cada término (independencia de Y y Z: $P(y, z) = P(y)P(z)$):

(y, z)	$P(x_1 \mid y, z)$	$P(y)$	$P(z)$	**Producto**
(y_1, z_1)	0,8	0,5	0,7	0,280
(y_1, z_2)	0,3	0,5	0,3	0,045
(y_2, z_1)	0,6	0,5	0,7	0,210
(y_2, z_2)	0,5	0,5	0,3	0,075
			$P(x_1) =$	**0,610**

3. Complemento: $P(x_2) = 1 - 0{,}61 = \mathbf{0{,}39}$.

Modelo básico: cálculo de $P(x_1)$ (*outputs*)

1. Descomponer el evento x_1 según todas las combinaciones de los padres (eventos disjuntos):

$$x_1 = x_1(y_1, z_1) \cup x_1(y_1, z_2) \cup x_1(y_2, z_1) \cup x_1(y_2, z_2)$$

$$P(x_1) = \sum_y \sum_z P(x_1 \mid y, z)\, P(y)\, P(z) \qquad (*)$$

2. Calcular cada término (independencia de Y y Z: $P(y, z) = P(y)P(z)$):

(y, z)	$P(x_1 \mid y, z)$	$P(y)$	$P(z)$	**Producto**
(y_1, z_1)	0,8	0,5	0,7	0,280
(y_1, z_2)	0,3	0,5	0,3	0,045
(y_2, z_1)	0,6	0,5	0,7	0,210
(y_2, z_2)	0,5	0,5	0,3	0,075
			$P(x_1) =$	**0,610**

3. Complemento: $P(x_2) = 1 - 0{,}61 = \mathbf{0{,}39}$.

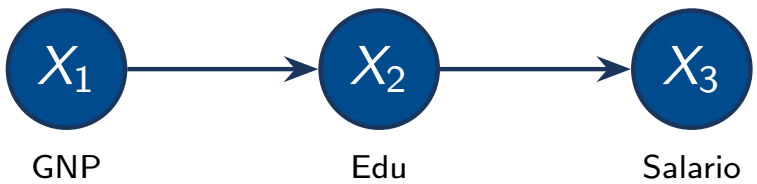
Y si observamos $X = x_1$ ... (razonamiento "hacia atrás" con Bayes)

$$P(y_1 \mid x_1) = (0{,}280 + 0{,}045)/0{,}61 = \mathbf{0{,}533} \quad \text{(antes 0,5)}$$
$$P(z_1 \mid x_1) = (0{,}280 + 0{,}210)/0{,}61 = \mathbf{0{,}803} \quad \text{(antes 0,7)}$$

Ejemplo: GNP, educación y salario (enunciado)

Considere los resultados simplificados de un estudio que relaciona el GNP (*Gross National Product*) de países, el nivel de educación recibida y el tipo de trabajo en edad adulta profesional.

- La variable x_1 es binaria y establece el **tipo de país**: HGP (*High-Gross-Product*) o de bajo GNP LGP.
- La variable x_2 genera tres posibles resultados: no educado NE, bajo nivel educativo LE y alto nivel educativo HE.
- Finalmente, la variable x_3 relacionada con el nivel económico de la retribución salarial: no empleado (*unemployed*) UN, bajo pago LP o alto pago HP.



Ejemplo: GNP, educación y salario (datos y preguntas)



Empleando una gran cantidad de datos, se encontraron las siguientes probabilidades:

$$P(x_1 = LGP) = 0{,}8, \qquad P(x_1 = HGP) = 0{,}2$$

Probabilidades condicionales:

$P(x_2 \mid x_1)$	NE	LE	HE
$x_1 =$ LGP	0,10	0,70	0,20
$x_1 =$ HGP	0,05	0,20	0,75

$P(x_3 \mid x_2)$	UN	LP	HP
$x_2 =$ NE	0,15	0,80	0,05
$x_2 =$ LE	0,10	0,85	0,05
$x_2 =$ HE	0,05	0,15	0,80

Preguntas

a) Exprese la probabilidad conjunta de la red.

b) Calcule la probabilidad de que alguien de un país rico (HGP), con alta educación (HE), tenga un alto salario (HP).

c) Verifique la condición de Markov (emplee el caso del inciso b).

Ref.: *Machine Learning*, Elsevier (2015). doi:10.1016/B978-0-12-801522-3.00016-1

Ejemplo GNP: solución a) y b)

a) Probabilidad conjunta

Aplicando $P(X_1, \ldots, X_n) = \prod_i P(X_i \mid PA(X_i))$ a la cadena $X_1 \to X_2 \to X_3$:

$$P(x_1, x_2, x_3) = P(x_3 \mid x_2)\, P(x_2 \mid x_1)\, P(x_1)$$

Condición de Markov: $x_3 \perp\!\!\!\perp x_1 \mid x_2 \;\Rightarrow\; P(x_3 \mid x_1, x_2) = P(x_3 \mid x_2)$

Ejemplo GNP: solución a) y b)

a) Probabilidad conjunta

Aplicando $P(X_1, \ldots, X_n) = \prod_i P(X_i \mid PA(X_i))$ a la cadena $X_1 \to X_2 \to X_3$:

$$P(x_1, x_2, x_3) = P(x_3 \mid x_2)\, P(x_2 \mid x_1)\, P(x_1)$$

Condición de Markov: $x_3 \perp\!\!\!\perp x_1 \mid x_2 \;\Rightarrow\; P(x_3 \mid x_1, x_2) = P(x_3 \mid x_2)$

b) País HGP, educación HE y salario HP

$$\begin{aligned} P(HGP, HE, HP) &= P(HP \mid HE)\; P(HE \mid HGP)\; P(HGP) \\ &= (0{,}8)(0{,}75)(0{,}2) = \mathbf{0{,}12} \end{aligned}$$

Es decir, el 12 % de la población cumple simultáneamente las tres condiciones.

Ejemplo GNP: solución c) verificar la condición de Markov

Debemos comprobar que $x_3 \perp\!\!\!\perp x_1 \mid x_2$, es decir,
$P(x_3 \mid x_1, x_2) = P(x_3 \mid x_2)$.

Lado izquierdo (definición de probabilidad condicional):

$$P(HP \mid HGP, HE) = \frac{P(HGP, HE, HP)}{P(HGP, HE)}$$

$$= \frac{P(HP \mid HE)\, P(HE \mid HGP)\, P(HGP)}{P(HE \mid HGP)\, P(HGP)}$$

$$= \frac{0{,}12}{(0{,}75)(0{,}2)} = \mathbf{0{,}8}$$

Lado derecho (directo de la tabla):

$$P(HP \mid HE) = \mathbf{0{,}8}$$

Conclusión

Ambos valores coinciden: una vez conocido el nivel educativo (x_2), saber si el país es rico o pobre (x_1) **no cambia** la probabilidad de tener un salario alto. Se cumple la condición de Markov.

Aplicaciones en toma de decisiones y evaluación de riesgo

Finanzas y riesgo

- Probabilidad de éxito de un cajero automático para seleccionar su ubicación (**Davivienda**).
- Valoración del **riesgo operativo** en una entidad financiera.
- Riesgo operativo en el abastecimiento de combustibles (**Ecopetrol**).
- Pronóstico de precios de acciones.

Educación

- Predicción de la **deserción estudiantil** en la Universidad de los Andes.

Salud

- Soporte a la decisión de **diagnóstico médico**: pacientes con sospecha de apendicitis.
- En general: a partir de las causas de una enfermedad, estimar la distribución del riesgo del paciente sobre los estados de la enfermedad.

Mercadeo

- Pre-evaluación del éxito de actividades promocionales (**Unilever** Food Solutions).
- Mercadeo de nuevos vehículos (**GM Colmotores**).

Patrón común: varias **causas** observables $\rightarrow$ **variables intermedias** $\rightarrow$ un **resultado** de interés para decidir.